

Análisis de los cambios de usos del Campo de Cartagena 1987–2009

MF Carreño

diciembre 2014

Índice

1. Resumen	1
2. Introducción	2
3. Análisis	2
3.1. Carga de datos	2
3.2. Preparación del análisis	2
Descripción de los datos	3
Selección del área de estudio	3
3.3. Análisis de correspondencias múltiples (ACM)	4
4. Resultados	5
4.1. Mapa de clases	5
4.2. Reclasificación	5
4.3. Perfiles de cambio	11

1. Resumen

Utilizando mapas de usos realizaremos la clasificación de los píxeles; para ello utilizaremos una clasificación de kmeans a partir de los primeros ejes de un MCA, finalmente reclasificamos las clases obtenidas para producir un mapa final.

- `resolucion`: Resolución a considerar
- `nmapas`: nombre de los mapas
- `nminpixclas`: número de píxeles por clases para despreciar en las clases
- `nclaseskm`: Número de clases en kmeans
- `semilla`: valor donde empieza el kmeans
- `nejesacm`: Número de ejes a retener en MCA
- `nclasesfinal` : N clases

```
nclaseskm    <- 200
nejesacm     <- 8
nclasesfinal <- 10
resolucion   <- '25x25'
nmapas       <- c( "c87", "c97", "c00", "c09" )
nminpixclas  <- 25
clasesAna    <- 1:4
semilla      <- 101
```

2. Introducción

En este documento se muestran los resultados del análisis de los mapas de usos correspondientes a la cuenca del Mar Menor, en el Campo de Cartagena (SE, España) para los años 1987, 1996, 2000 y 2009.

```
library( FactoMineR )
library( raster )

## Loading required package: methods
## Loading required package: sp

library( rgdal )

## rgdal: version: 0.8-16, (SVN revision 498)
## Geospatial Data Abstraction Library extensions to R successfully loaded
## Loaded GDAL runtime: GDAL 1.10.1, released 2013/08/26
## Path to GDAL shared files: /usr/share/gdal/1.10
## Loaded PROJ.4 runtime: Rel. 4.8.0, 6 March 2012, [PJ_VERSION: 480]
## Path to PROJ.4 shared files: (autodetected)

library( stats )
#library( igraph )
```

3. Análisis

El análisis elegido para caracterizar la evolución de los cambios de usos a lo largo del periodo de estudio (1987 – 2009) son el ACM (Análisis de Correspondencias múltiples), el Kmeans y la clasificación jerárquica con el criterio de Ward.

Par su aplicación se ha procedido a realizar en primer lugar una reclasificación de los doce usos originales (AND, ANC, MD, MC, SH, SA, RH, RA, INV, IMP, CA, SAL) cinco. La clase 1 incluye los usos naturales (arbolados y matorrales tanto denso como claros denso y claro: AND, ANC, MD y MC), la clase 2 los secanos (herbáceos y arbóreos: SH y SA), la clase 3 los regadíos (herbáceos, arbóreos e invernaderos: RA, RH e INV), la clase 4 los improductivos (IMP) en los que se incluye el suelo desnudo, infraestructuras y suelos urbanos principalmente y, por último la clase 5 los cuerpos de agua (CA). La clase SAL (salinas) se ha sacado del análisis puesto que esta clase prácticamente no ha sufrido cambios y su escasa extensión.

3.1. Carga de datos

Los mapas estan almacenados en los fichero raster...

```
r1 <- raster( paste( resolucion, "/C87_cl5.gri", sep="" ) )
r2 <- raster( paste( resolucion, "/C97_cl5.gri", sep="" ) )
r3 <- raster( paste( resolucion, "/C00_cl5.gri", sep="" ) )
r4 <- raster( paste( resolucion, "/C09_cl5.gri", sep="" ) )
rt <- r1
```

3.2. Preparación del análisis

Contruimos una imagen con todas la capas reclasificadas en 5 clases.

```
rcu <- stack( list( r1, r2, r3, r4 ) )
names( rcu ) <- nmapas
```

Descripción de los datos

```
plot( rcu )
```

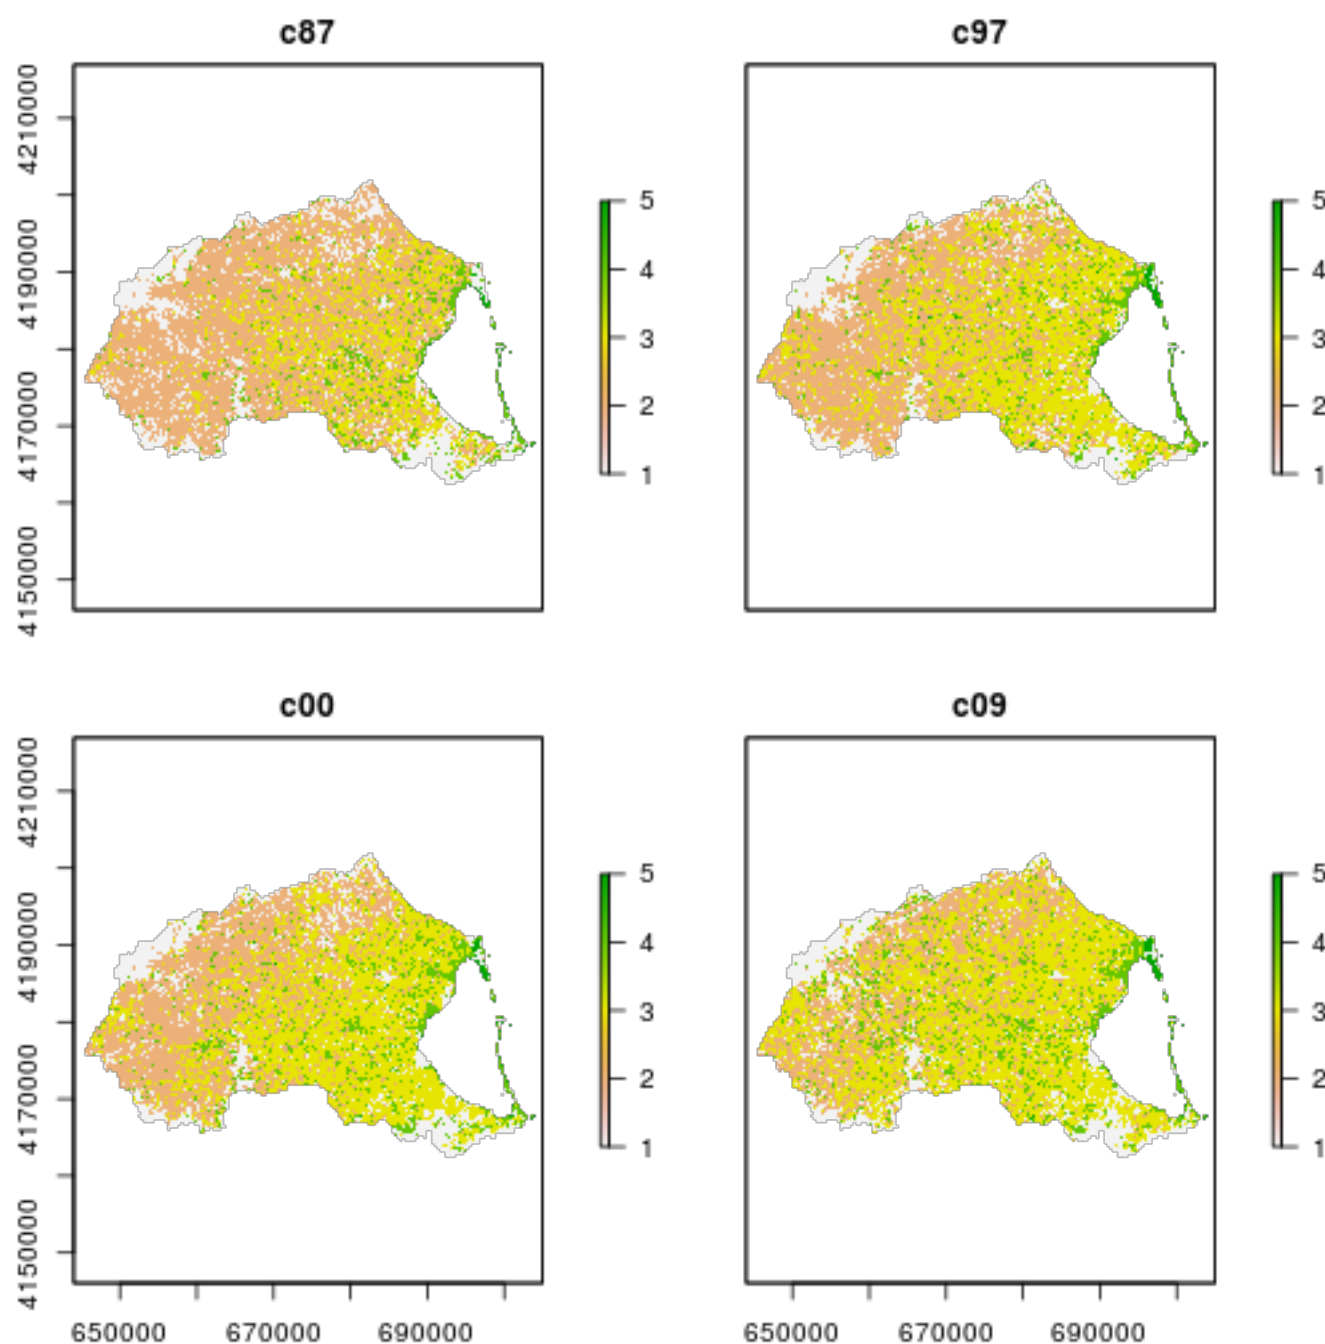


Figura 1: plot of chunk mapasCambios

```
cambiosusos <- crosstab( rcu )
write.table( cambiosusos, "cambioUsos.dat" )
cambiosusos <- cambiosusos[ cambiosusos$Freq > nminpixclas, ]
dim( cambiosusos )
## [1] 320 5
```

Selección del área de estudio

Aproximadamente la mitad de los píxeles recogidos en los ficheros son ajenos al área de estudio; los seleccionamos para eliminarlos de la tabla de datos al realizar el análisis.

```

selNoNA <- !is.na( values( r1 ) )
selClas <- ( values( r1 ) %in% clasesAna ) &
           ( values( r2 ) %in% clasesAna ) &
           ( values( r3 ) %in% clasesAna ) &
           ( values( r4 ) %in% clasesAna )

selcel <- selNoNA & selClas

```

3.3. Análisis de correspondencias múltiples (ACM)

Realizamos el análisis para los píxeles del área de estudio, calculando los ocho primeros ejes. Posteriormente clasificamos los píxeles en grupos atendiendo al número máximo de perfiles de cambio aparecidos en el área de estudio.

```

rcud <- as.data.frame( values( rcu )[ selcel, ] )
for (i in 1:ncol( rcud ) ) rcud[ , i ] <- as.factor( rcud[ , i ] )
summary(rcud)

##      c87      c97      c00      c09
## 1: 376904 1:327817 1:330622 1:323799
## 2:1118951 2:776616 2:688524 2:503142
## 3: 402331 3:749900 3:831227 3:972179
## 4: 121987 4:165840 4:169800 4:221053

x.mca <- MCA( rcud, ncp = nejesacm )
x.mca$eig

##      eigenvalue percentage of variance cumulative percentage of variance
## dim 1      0.6523                21.743                21.74
## dim 2      0.5024                16.745                38.49
## dim 3      0.4671                15.571                54.06
## dim 4      0.2177                 7.255                61.31
## dim 5      0.1896                 6.319                67.63
## dim 6      0.1741                 5.803                73.44
## dim 7      0.1670                 5.568                79.00
## dim 8      0.1492                 4.972                83.98
## dim 9      0.1393                 4.645                88.62
## dim 10     0.1262                 4.205                92.83
## dim 11     0.1108                 3.694                96.52
## dim 12     0.1044                 3.479               100.00

write.table( x.mca$var$coord, "coodenadasVariablesMCA.dat" )

plot( x.mca$var$coord[ , 1:2],type = "n",
      main = "MCA: Ejes 1 y 2, variables",
      xlim = ( c(-0.1,0.1) + range( x.mca$var$coord[ , 1] ) ) * 1.2,
      ylim = range( x.mca$var$coord[ , 2] )*1.1
    )
abline(v = 0, h = 0, col = "grey" )
text( x.mca$var$coord[ , 1:2], rownames( x.mca$var$coord[ , 1:2] ) )

rmca <- rt
values( rmca )[ selcel ] <- x.mca$ind$coord[ , 1 ]

```

```

for (i in 2:nejesacm){
  rt <- r1
  values( rt )[ selcel ] <- x.mca$ind$coord[ , i ]
  rmca <- addLayer( rmca, rt )
}
names( rmca ) <- paste( "Eje", 1:nejesacm, sep="" )
values( rmca )[ !selNoNA ] <- NA
writeRaster( rmca, "coordenadasMCA", overwrite = TRUE )

## class      : RasterBrick
## dimensions  : 1640, 2440, 4001600, 8  (nrow, ncol, ncell, nlayers)
## resolution  : 25, 25  (x, y)
## extent      : 644000, 705000, 4161000, 4202000  (xmin, xmax, ymin, ymax)
## coord. ref. : +proj=utm +zone=30 +ellps=intl +units=m +no_defs
## data source : /disco/home/paquicf/git/paquicf/tesis/capitulo3/material/cambioUsos/analisis
## names       : Eje1, Eje2, Eje3, Eje4, Eje5, Eje6, Eje7, Eje8
## min values   : -0.6805, -1.0421, -1.0797, -0.8191, -1.2500, -1.6298, -1.7661, -1.7714
## max values   :      5,      5,      5,      5,      5,      5,      5,      5

plot( rmca )

nc <- nclaseskm
set.seed(semilla)
kmeans( x.mca$ind$coord, nc ) -> x.mca.km

plot( x.mca$var$coord[ , 1:2], type = "n",
      main = "MCA: Ejes 1 y 2, variables y clases",
      xlim = ( c( -0.1, 0.1 ) + range( x.mca$var$coord[ , 1] ) ) * 1.2,
      ylim = range( x.mca$var$coord[ , 2] ) * 1.1
    )
abline(v = 0, h = 0, col = "grey" )
text( x.mca.km$cen[, 1:2], as.character( 1:nc ) )
text( x.mca$var$coord[ , 1:2], rownames( x.mca$var$coord[ , 1:2] ), col=2 )

```

4. Resultados

4.1. Mapa de clases

El mapa de clases obtenido de la partición es:

```

rclas <- r1
values( rclas ) <- NA
values( rclas )[ selcel ] <- x.mca.km$c1
#values( rclas )[!selNoNA] <- NA
plot( rclas )

```

4.2. Reclasificación

Clasificación herarquica de las clases obtenidas en la partición.

```

x.hclus.cen <- hclust( dist( x.mca.km$cen ), method = "ward.D" )
plot( x.hclus.cen, hang = -1 )

```

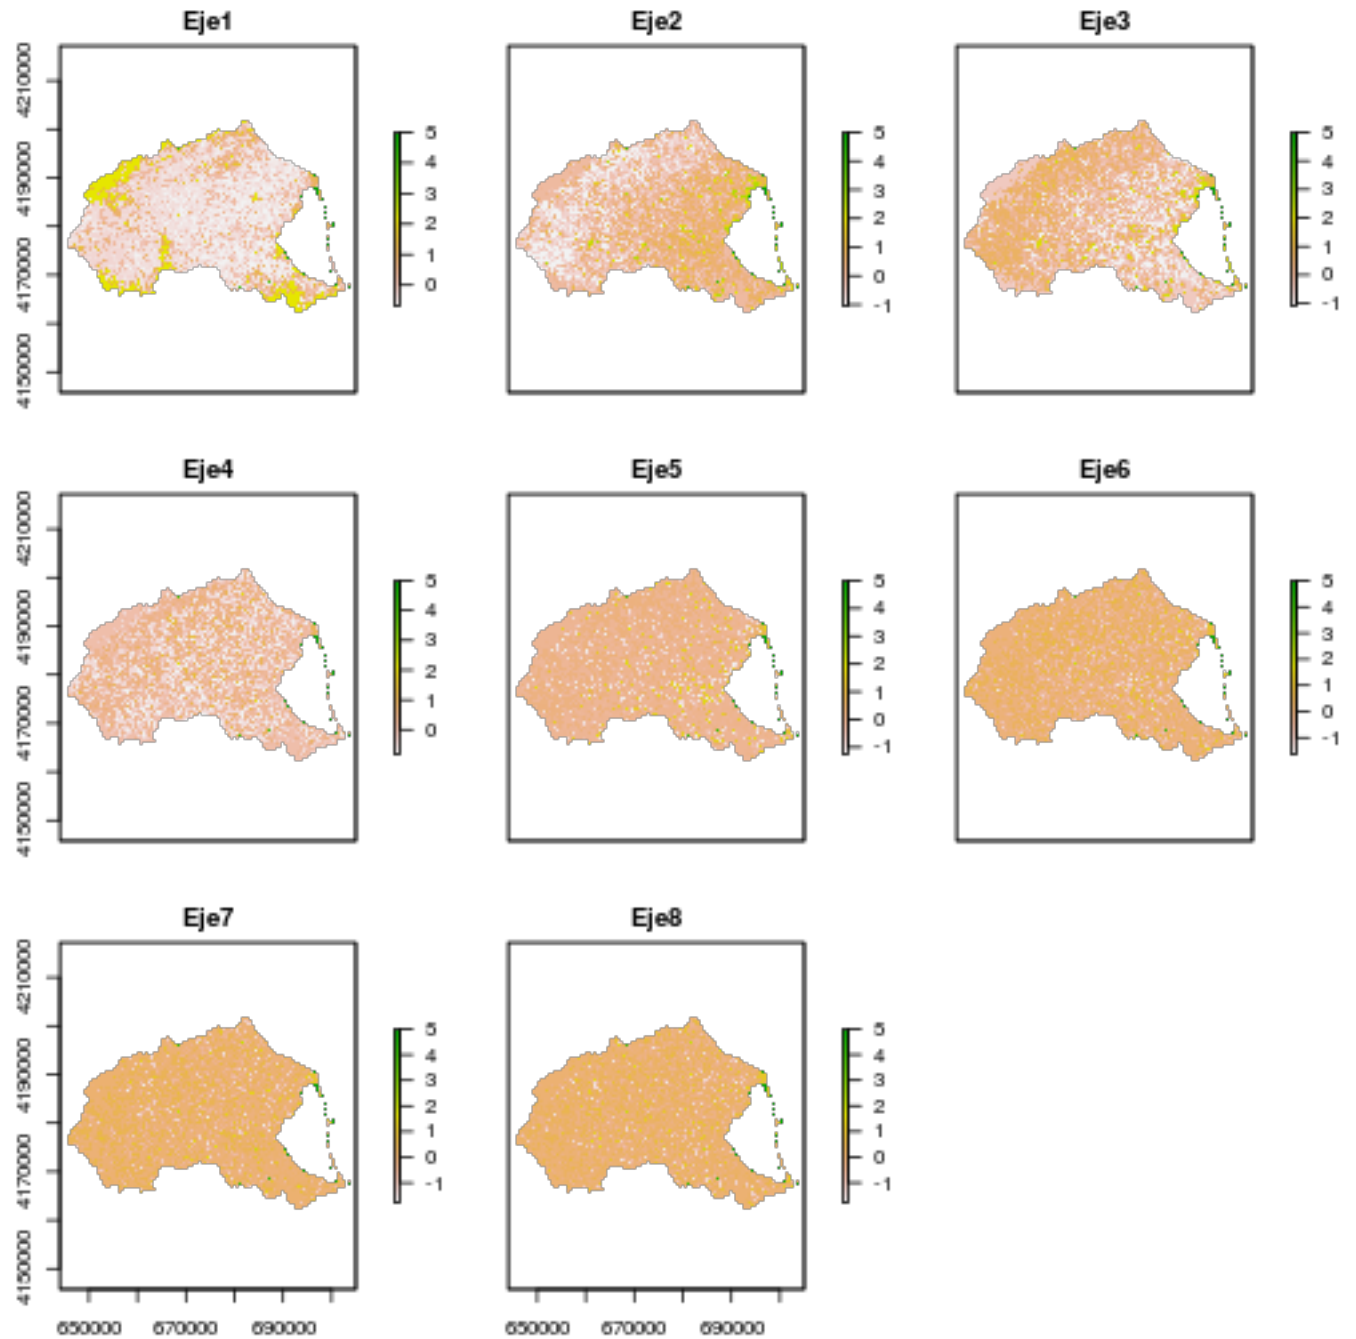


Figura 2: plot of chunk KMEANS




Figura 3: plot of chunk KMEANS

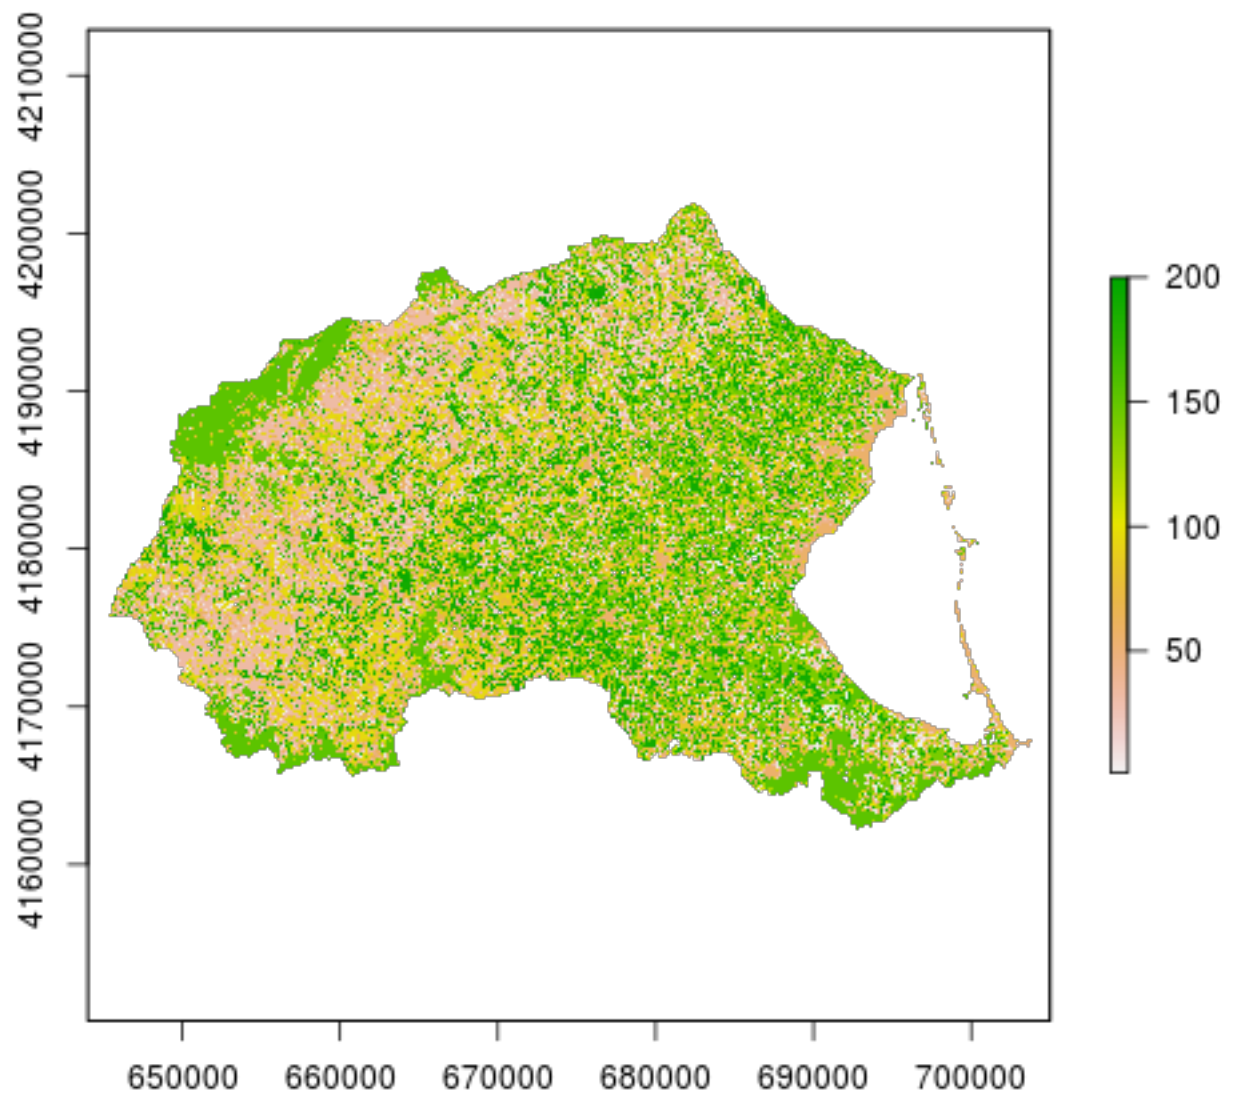


Figura 4: plot of chunk mapaclases




Figura 5: plot of chunk hcluster

```
cutree( x.hclus.cen, nclasesfinal ) -> reasignacion

rclas2 <- reclassify( rclas, data.frame(1:nc,reasignacion) )
plot( rclas2 )
```

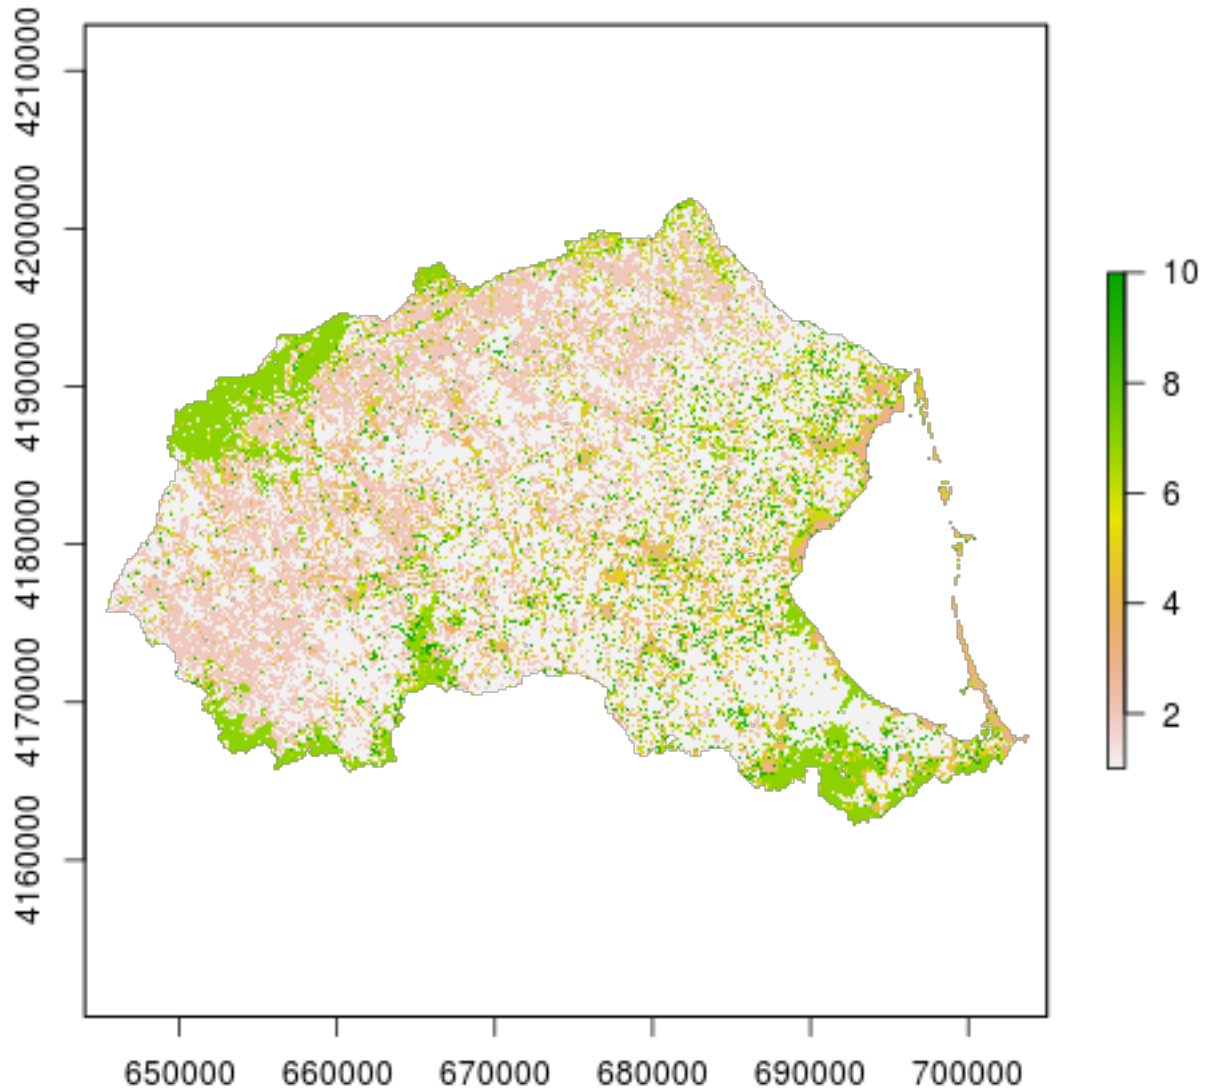


Figura 6: plot of chunk hcluster

```
writeRaster( stack( rclas2, rclas ), "clasificaciones", overwrite = TRUE )

## class      : RasterBrick
## dimensions  : 1640, 2440, 4001600, 2  (nrow, ncol, ncell, nlayers)
## resolution  : 25, 25  (x, y)
## extent      : 644000, 705000, 4161000, 4202000  (xmin, xmax, ymin, ymax)
## coord. ref. : +proj=utm +zone=30 +ellps=intl +units=m +no_defs
## data source : /disco/home/paquicf/git/paquicf/tesis/capitulo3/material/cambioUsos/analisis
```

```
## names      : layer, C87_c15
## min values :      1,      1
## max values :     10,     200
```

4.3. Perfiles de cambio

Identificación de los perfiles de cambios, a partir de la creación de tablas para determinar a que clase han sido asignados los diferentes perfiles y, si esos perfiles se dan en manchas grandes que marcarían las tendencias de cambios o pequeñas que realmente podrían suponer ruido.

Genero el mapa de manchas en GRASS pues el creado en R no etiqueta a las manchas una a una.

Primero exporto el mapa de clasificaciones.

```
raster("clasificaciones.grd") -> clasificaciones
writeRaster(clasificaciones, filename="clasificaciones.tif", format="GTiff", overwrite=TRUE)

## class      : RasterLayer
## dimensions : 1640, 2440, 4001600 (nrow, ncol, ncell)
## resolution : 25, 25 (x, y)
## extent     : 644000, 705000, 4161000, 4202000 (xmin, xmax, ymin, ymax)
## coord. ref.: +proj=utm +zone=30 +ellps=intl +units=m +no_defs
## data source: /disco/home/paquicf/git/paquicf/tesis/capitulo3/material/cambioUsos/analisis
## names      : clasificaciones
## values     : 1, 10 (min, max)
```

Y en grass genero el mapa de manchas y lo exporto.

```
r.in.gdal -o --o in=clasificaciones.tif out=clasificaciones
g.region rast=clasificaciones
r.clump --o in=clasificaciones out=clasificacionesM
r.stats -c clasificacionesM >rules
awk '{print $1 "=" $2}' rules >rules_c
cat rules_c|r.reclass --o clasificacionesM out=clasificacionesMc
r.mapcalc 'clasificacionesMci=int(clasificacionesMc)'
r.out.gdal in=clasificacionesMci type=UInt32 out=clasificacionesM.tif nodata=*
```

Lo importo a R.

```
library(raster)
raster("clasificacionesM.tif") -> m
s <- m
values(s)[values(s) < 1] <- NA
#freq(s)
plot(s)
writeRaster(s, "clasificacionesM", overwrite=TRUE)

## class      : RasterLayer
## dimensions : 1640, 2440, 4001600 (nrow, ncol, ncell)
## resolution : 25, 25 (x, y)
## extent     : 644000, 705000, 4161000, 4202000 (xmin, xmax, ymin, ymax)
## coord. ref.: +proj=utm +zone=30 +ellps=intl +towgs84=-131,-100.3,-163.4,-1.244,-0.02,-1.
## data source: /disco/home/paquicf/git/paquicf/tesis/capitulo3/material/cambioUsos/analisis
## names      : layer
## values     : 1, 262845 (min, max)

raster("clasificacionesM.grd") -> clasificacionesM
plot(clasificacionesM)
```

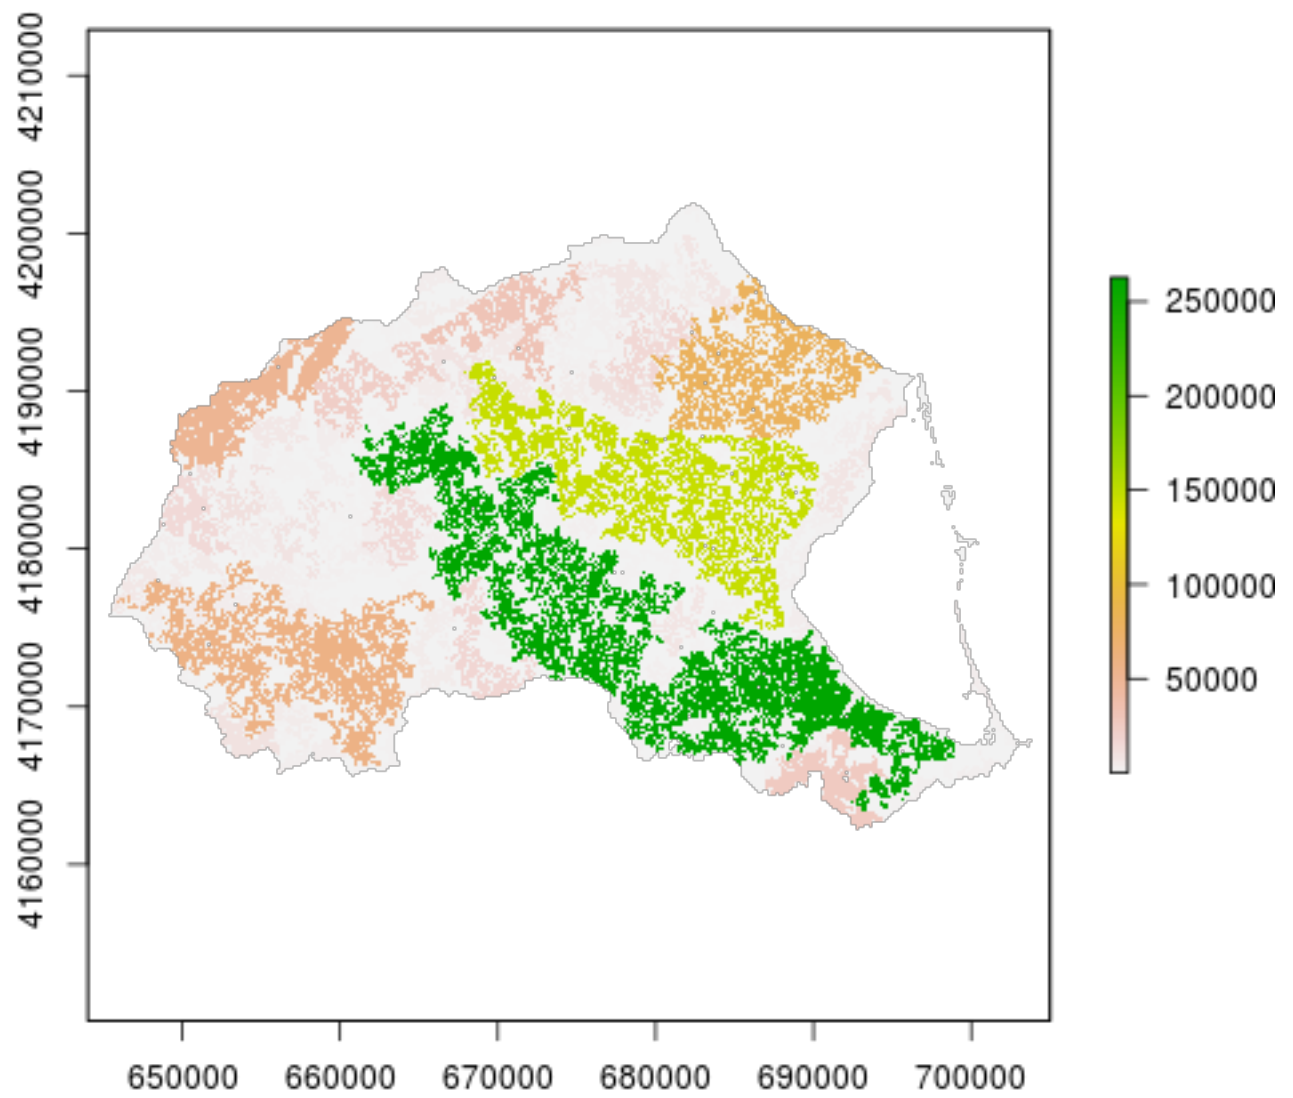


Figura 7: plot of chunk impM

```
#freq(clasificacionesM)
rm(s,m)
```

Creo la tabla de perfiles: usos y a que clase se han adjudicado.

```
rcuC<- stack( list( r1, r2, r3, r4, clasificaciones ) )
crosstab(rcuC) -> tablaUC
head(tablaUC)
```

```
##   Var1 Var2 Var3 Var4 Var5 Freq
## 1    1    1    1    1    1    0
## 2    2    1    1    1    1 13905
## 3    3    1    1    1    1   394
## 4    4    1    1    1    1    0
## 5    5    1    1    1    1    0
## 6 <NA>    1    1    1    1    0
```

```
tail(tablaUC)
```

```
##           Var1 Var2 Var3 Var4 Var5      Freq
## 14251         1 <NA> <NA> <NA> <NA>        0
## 14252         2 <NA> <NA> <NA> <NA>        0
## 14253         3 <NA> <NA> <NA> <NA>        0
## 14254         4 <NA> <NA> <NA> <NA>        0
## 14255         5 <NA> <NA> <NA> <NA>        0
## 14256 <NA> <NA> <NA> <NA> <NA> 1964338
```

```
tablaUC[,6]>10 & !is.na(tablaUC[,5]) -> sel
tablaUC[ sel, ]->tablaPUC
head(tablaPUC)
```

```
##   Var1 Var2 Var3 Var4 Var5 Freq
## 2    2    1    1    1    1 13905
## 3    3    1    1    1    1   394
## 7    1    2    1    1    1  6550
## 8    2    2    1    1    1  6624
## 9    3    2    1    1    1   339
## 13   1    3    1    1    1  3984
```

```
tail(tablaPUC)
```

```
##           Var1 Var2 Var3 Var4 Var5 Freq
## 12208         4    1    4    3   10  896
## 12214         4    2    4    3   10 1159
## 12220         4    3    4    3   10 3065
## 12424         4    1    4    4   10 1604
## 12430         4    2    4    4   10 1532
## 12436         4    3    4    4   10 2507
```

```
write.table(tablaPUC, file='tablaPUC.csv')
```

Creo la tabla de tamaños: clases a que tamaño de mancha corresponden.

```
rcCM <- stack( list(clasificaciones, clasificacionesM ) )
crosstab(rcCM) -> tablaCM
tablaCM[,3]>0 & !is.na(tablaCM[,2]) -> sel
tablaCM[ sel, ]->tablaPCM
head(tablaPCM)
```

```
##   Var1 Var2  Freq
## 1    1    1 12687
## 2    2    1  8731
## 3    3    1  5126
## 4    4    1 10358
## 5    5    1 13589
## 6    6    1 18063
```

```
tail(tablaPCM)
```

```
##      Var1  Var2  Freq
## 6299    7 50938 50938
## 6305    2 57815 57815
## 6315    1 58357 58357
## 6326    1 79183 79183
## 6337    1 146723 146723
## 6348    1 262845 262845
```

```
write.table(tablaPCM, file='tablaPCM.csv')
```